📚 Data Engineering Assignment (Open-Ended)

📌 Dataset

Use the following dataset as your source system:
👉 https://www.kaggle.com/datasets/terencicp/e-commerce-dataset-by-olist-as-an-sqlite-database

---

🎯 Objective

You are tasked with designing and implementing a **production-ready data warehouse solution** for an e-commerce business.

The goal is to enable **scalable, high-performance analytical reporting**.

🧩 Requirements

1. Data Warehouse Design

Design a data warehouse from the provided dataset.

You are free to choose:

- Architecture (Kimball, Inmon, Medallion, or hybrid)
- Modeling approach
- Table structures

⚠️ You must justify your design decisions.

أولا: Architecture:

Hybrid Medallion + Kimball Serving Layer

التبرير **:**اعتمدت معمارية هجينة بحيث تستخدم طبقات الميدالية لتنظيم تدفق البيانات تدريجياً من البيانات الخام إلى البيانات النظيفة ثم إلى الطبقة التحليلية، بينما تستخدم نمذجة كيمبال في الطبقة النهائية لبناء جداول الحقائق والأبعاد بطريقة مناسبة للتقارير والتحليل

طبقات الميدالية المستخدمة:

- طبقة برونزية**:** استخراج البيانات الخام من SQLite
- طبقة فضية **:**تنظيف البيانات، التحقق من الجودة، وتوحيد الأنواع
- طبقة ذهبية **:**بناء Star Schema وتحميل جداول Fact و Dimensionإلى PostgreSQL

ثانيا: Modelling approach

اتباع منهجية Kimball

التبرير :تتيح هذه المنهجية تحديد أدنى مستوى من التفاصيل لكل عملية تجارية مما يضمن دقة متناهية عند إجراء العمليات الحسابية المعقدة في التقارير النهائية

ثالثا :Table structures

اختيار شكل ال Star Schema

التبرير :تم اختيار Star Schema لأنه يوفر نموذجاً بسيطاً ومباشراً لربط جداول الحقائق بالأبعاد مما يقلل تعقيد الاستعلامات ويحسن أداء التجميعات ويسهل استخدامه في أدوات ذكاء الأعمال

الخلاصة:

لقد اخترت استخدام بايثون كمحرك بدلاً من النقل المباشر لأن حجم البيانات في التكليف يسمح بمعالجتها في الذاكرة مما يعطينا تحكماً كاملاً في جودة البيانات قبل صبها في مستودع البيانات هذا التوازن يحقق الأداء العالي وسهولة التوسع المطلوبة في التكليف

2. Data Modeling

- Identify business processes “note: they may be more than business process happens in your business, each one shall represent a fact table”
- Define facts and dimensions (if applicable)
- Handle data granularity correctly
- Address data quality issues

No predefined schema will be provided.

أولا: Business Processes

قمت بتحديد خمس عمليات أساسية:

- **إدارة المبيعات والطلبات :**تهدف لتحليل تفاصيل مبيعات المنتجات وأداء البائعين
- **الشؤون المالية والمدفوعات :**تهدف لتحليل الإيرادات وطرق الدفع وتفاصيل الأقساط
- **تجربة العملاء :**تهدف لتحليل رضا العملاء من خلال التقييمات المسجلة
- **التوصيل والتأخير :**تهدف لتحليل سرعة الشحن وأسباب تأخر الطلبات
- **استقطاب البائعين :**تهدف لتحليل مسار تحويل البائعين المحتملين إلى شركاء فعليين

ثانيا: Facts and Dimensions

جداول الأبعاد المشتركة والفردية:

- بعد التاريخ، بعد العملاء، بعد المنتجات، بعد البائعين، بعد الطلبات، بعد التقييمات، بعد المدفوعات، بعد البائعين المحتملين

جداول الحقائق

- **جدول حقائق تفاصيل الطلبات :**يربط المبيعات بالمنتج والعميل والبائع والطلب والتاريخ
- **جدول حقائق المدفوعات :**يربط المدفوعات بالطلب والعميل ووسيلة الدفع والتاريخ
- **جدول حقائق التقييمات :**يربط التقييمات بالمنتج والطلب والعميل والبائع والتاريخ
- **جدول حقائق أداء التوصيل :**يربط أداء الشحن بالطلب والبائع والمنتج والتاريخ و العميل
- **جدول حقائق تحويل البائعين :**يربط بيانات البائعين الجدد ببعد التاريخ وبعد بيانات البائعين المحتملين

ثالثا :Data Granularity

في المبيعات :مستوى التفصيل هو سطر منتج واحد لكل طلب، مما يسمح بتحليل أداء كل منتج بشكل منفصل

في المدفوعات :مستوى التفصيل هو كل حركة دفع مرتبطة بطلب لاستيعاب تعدد وسائل الدفع أو الأقساط

في التقييمات :مستوى التفصيل هو كل تقييم فردي يتركه العميل

في التوصيل :مستوى التفصيل هو كل عملية توصيل منفصلة لقياس التأخير وأداء الشحن بدقة

في الاستقطاب :مستوى التفصيل هو كل بائع محتمل لتتبع كفاءة تحويله إلى شريك فعلي

رابعا: Data Quality

- **المفاتيح البديلة :**استخدام مفاتيح رقمية تسلسلية لضمان استقلالية المستودع عن تغييرات نظام المصدر وتحسين سرعة الربط
- **منطقية المقاييس :**التحقق برمجياً من أن قيم delivery_days وlate_days ناتجة عن فروقات زمنية صحيحة وغير سالبة
- **التحقق من نطاق التقييمات :**التأكد من أن review_score يقع ضمن النطاق المسموح به فقط ومعالجة أي قيم شاذة قد تؤثر على التحليل
- **تكامل البيانات المالية :**مطابقة إجمالي payment_value في جدول المدفوعات مع قيم المبيعات لضمان عدم فقدان أي مبالغ أثناء عملية النقل
- **معالجة القيم المفقودة :**معالجة القيم الناقصة وفق قواعد العمل المناسبة بدلاً من استبدالها بقيم قد تشوه النتائج التحليلية

يتميز هذا النموذج بقدرته على الإجابة على مختلف أسئلة الأعمال إذ يمكن ربط جدول حقائق المبيعات ببعد التاريخ لمعرفة اتجاهات البيع عبر الزمن وربطه ببعد المنتجات لمعرفة الفئات الأعلى ربحية كما يمكن استخدام جدول حقائق أداء التوصيل لتحليل أسباب التأخير من خلال الربط مع أبعاد البائعين والمنتجات والموقع الجغرافي مما يجعل النموذج مناسباً للتقارير التحليلية واتخاذ القرار

ملاحظة :لن يتم استخدام جميع جداول الابعاد والحقائق بل سيتم استخدام الجداول التي تخدم أسئلة البزنس وهي جداول الابعاد التالية بعد التاريخ وبعد العملاء بعد المنتجات بعد البائعين بعد الطلبات وجدولي الحقائق جدول حقائق تفاصيل الطلبات وجدول حقائق أداء التوصيل

3. Data Pipeline (ETL/ELT)

Build a pipeline to move data from source to target system.

You are free to choose:

- Tools (Python, SQL, etc.)
- Approach (batch, incremental, etc.)

Your pipeline should:

- Be reproducible
- Handle failures
- Be reasonably scalable

أولا: Tools and Approach

- **الأدوات:** python, pandas, SQLAlchemy
- **النهج:** معالجة بالدفعات بنظام التحديث الكامل لضمان اتساق البيانات

ثانياً:Workflow

1. **الاستخراج:** قراءة الجداول الخام من ملف SQLite
2. **التحويل:** تنظيف البيانات ومعالجة القيم المفقودة

   - إنشاء المفاتيح البديلة لجداول الأبعاد
   - حساب مقاييس الأداء أيام التأخير وربط الجداول لتشكيل جداول الحقائق

3. **التحميل:** رفع الجداول النهائية المهيكلة Star Schema

ثالثاً: معايير الجودة

- قابلية إعادة التشغيل :تم تصميم الكود حيث يقوم بتحديث المستودع بالكامل في كل دورة تشغيل دون تكرار السجلات مما يضمن ثبات النتائج
- التعامل مع الإخفاقات :استخدام جمل Try-Except
- قابلية التوسع :تم بناء الكود بشكل يسهل عملية تطويره مستقبلاً

ملاحظة: يمكنكم الاطلاع على التنفيذ البرمجي الكامل والخطوات التفصيلية لكل جدول في الملف المرفق

5. Performance Optimization

Your solution must consider performance.

Examples (not limited to):

- Partitioning
- Indexing

Performance Optimization

لضمان سرعة الاستجابة وكفاءة المستودع تم تطبيق استراتيجيات تحسين الأداء التالية:

- **الفهرسة** :تم إنشاء فهارس على المفاتيح الخارجية في جداول الحقائق هذا يقلل من زمن تنفيذ عمليات الربط والتصفية بشكل كبير
- **المفاتيح البديلة** :تم استبدال المعرفات النصية المعقدة بمفاتيح رقمية لتقليل حجم الفهارس وتسريع المقارنات داخل محرك قاعدة البيانات

ملاحظة :يمكنكم الاطلاع على التنفيذ البرمجي الكامل والخطوات التفصيلية لكل جدول في الملف المرفق

6. Reporting Layer

Enable business users to answer questions such as:

- How are sales trending over time?
- Who are the most valuable customers?
- What affects delivery performance?
- Which products/categories drive revenue?

طبقة التقارير(Reporting Layer)

- **اتجاهات المبيعات عبر الزمن :**
  - ربط جدول الحقائق fact_order_items بجدول الأبعاد dim_date باستخدام مفتاح date_key
  - المقاييس **:**تجميع عمود sales_amount حسب (الشهر والسنة) من بعد الوقت
- **تحديد العملاء الأكثر قيمة :**
  - تجميع إجمالي المبالغ في fact_order_items حسب customer_key المرتبط بجدول dim_customer
  - المقاييس **:**ترتيب النتائج تنازلياً حسب إجمالي sales_amount واستخدام customer_unique_id للتعريف الفريد
- **مسببات أداء التوصيل :**
  - استخدام جدول fact_delivery_performance وربطه بأبعاد المنتجات weight_category والجغرافيا from_state و to_state
- **الفئات الأكثر ربحية :**
  - ربط جدول fact_order_items بجدول dim_product الذي يحتوي على الترجمة الإنجليزية الجاهزة
  - المقاييس **:**تجميع sales_amount و quantity حسب فئة المنتج product_category_name_english

ملاحظة :يمكنكم الاطلاع على التنفيذ البرمجي الكامل والخطوات التفصيلية لكل جدول في الملف المرفق

7. Documentation (VERY IMPORTANT)

Document your work clearly:

- Architecture diagram
- Data model
- Pipeline design
- Key assumptions
- Trade-offs

Trade-offs

- **مخطط النجمة مقابل الجدول الكبير الواحد :**ساهم هذا الاختيار في تقليل تكرار البيانات المخزنة مما أدى إلى كفاءة أفضل في استهلاك المساحة التخزينية
- **الفهرسة مقابل التقسيم :**تم الاعتماد على الفهرسة فقط وتجنب عملية تقسيم الجداول يعود السبب في ذلك إلى أن حجم البيانات الحالي يقل عن مليون سجل وهي كمية توفر فيها الفهارس سرعة استعلام ممتازة جداً
- **مكتبة بانداس مقابل سبارك:** حجم مجموعة البيانات يتناسب تماماً مع ذاكرة الجهاز الواحد ساعد هذا القرار في تسريع وتيرة التطوير واختصار زمن التنفيذ متجنبين بذلك الحاجة إلى تقنيات البيانات الضخمة التي تتطلب موارد حوسبة أعلى وإعدادات بيئية أكثر تعقيداً لا يحتاجها حجم العمل الحالي
- **التحميل الكامل مقابل التحميل التدريجي**: تم الاعتماد على التحميل الكامل في طبقة ال Staging لضمان سهولة إعادة التشغيل ولكن في طبقة الأبعاد تم اختيار استراتيجية SCD Type 2 بدلاً من الاستبدال الكلي هذا القرار سمح لنا بالحفاظ على سجلات تاريخية لتغيرات مواقع العملاء والبائعين وهو أمر ضروري لتحليل أداء التوصيل بدقة عبر الزمن

🎁 Deliverables

Submit:

1. Data model (diagram + explanation)
2. ETL/ELT implementation
3. Target schema (DWH)
4. Sample analytical queries
5. Documentation of decisions

🧠 Evaluation Criteria

Area	What we look for
Thinking	Do you make good design decisions?
Modeling	Correct handling of grain, relationships
Engineering	Clean, scalable pipeline
Performance	Awareness of optimization techniques
Communication	Clear justification of choices

🔥 Notes

- There is **no single correct solution**
- Over-engineering is as bad as under-engineering
- We care more about **why** than **what**