Apache NiFi Assignment: Real-Time Data Ingestion & Processing

1. Real-Time Data Simulation

Create a script (Python, Bash, or any language) that generates data continuously to simulate real-time streaming.
The generated data should be semi-structured (e.g., CSV,txt,json) and slightly messy (missing values, inconsistent formats, duplicates).
The script should write files periodically (e.g., every few seconds) and store them in a directory to be ingested by NiFi.

محاكاة البيانات في الوقت الفعلي

الأهداف التي حققتها في هذه المرحلة:

قمت بتصميم وبناء سكربت محاكاة متكامل يعمل على توليد تدفق مستمر من البيانات بصيغة جيسون وذلك لتمثيل تدفق البيانات في الوقت الفعلي ركزت في هذا السكربت على إنتاج بيانات غير منتظمة تحتوي على مشكلات مقصودة بهدف الاختبار

وصف الحل التقني الذي نفذته:

لقد استخدمت لغة بايثون لتطوير سكربت برمجي يقوم بدور المنتج للبيانات يعمل هذا النص على إنشاء ملفات بشكل دوري وحفظها في مجلد محدد على القرص الصلب الخاص بي وقد قمت بربط هذا المجلد تقنياً بنظام دوكر لضمان قدرة نظام ناي فاي على الوصول للملفات وقراءتها فور صدورها.

الميزات التقنية التي أضفتها لنظام المحاكاة:

1. التوليد اللحظي المستمر: برمجت السكربت ليقوم بإنتاج ملف جديد كل ٥ ثوان بشكل آلي دون توقف
2. بنية السجلات المتعددة: جعلت كل ملف يحتوي على مجموعة من السجلات من ٢ إلى ٥ سجلات مما يحاكي الواقع العملي لتدفق البيانات
3. محاكاة فوضى البيانات:

- معالجة القيم المفقودة: قمت ببرمجة النظام ليترك حقول المبلغ أو الحالة فارغة بشكل عشوائي في بعض السجلات
- التنسيقات غير القياسية: تعمدت إدخال رموز ونصوص غير منطقية في بعض الحقول لاختبار مهارات الفلترة والتنقية
- السجلات المكررة: قمت بإضافة منطق برمجي يقوم بحقن سجلات مكرره في نفس الملف لاختبار ناي فاي في معالجة السجلات المكررة

2. File-Based Ingestion using NiFi

Use NiFi processors to ingest the generated files using the mandatory approach:
ListFile → FetchFile
Apply best practices such as handling duplicates, ensuring no data loss, and proper scheduling.

أولاً: معالج ListFile

قمت بإضافة هذا المعالج ليعمل ككشاف ذكي يراقب المجلد المشترك تتمثل وظيفته الأساسية في رصد الملفات الجديدة وجرد بياناتها الوصفية دون قراءة المحتوى مما يسمح للنظام بمعرفة ما يجب معالجته لاحقا

ثانياً: معالج FetchFile

بناء على التقارير الواردة من المعالج السابق يقوم هذا المعالج بالدخول إلى الملفات وقراءة محتواها الفعلي وتحويلها إلى تدفق بيانات داخلي لقد طبقت هنا استراتيجية الحذف التلقائي للملف فور اكتمال جلبه وذلك لضمان عدم تكرار المعالجة وللحفاظ على مساحة التخزين في الخادم

أفضل الممارسات التقنية التي طبقتها في هذا الجزء:

- الجدولة الزمنية الدقيقة: قمت بضبط وتيرة العمل لتكون كل أربع ثوان مما يضمن تزامن عملية السحب مع عملية توليد البيانات ويمنع تراكم الملفات أو إرهاق موارد النظام
- منع فقدان البيانات: قمت بتصميم مسارات بديلة لجميع حالات الفشل المحتملة وربطتها بمعالجات LogAttribute تضمن عدم ضياع أي سجل بيانات في حال حدوث خطأ أثناء القراءة أو الجلب
- إدارة التكرار وضمان الصحة: قمت بتهيئة بوابات المخرج لنقل البيانات النظيفة فقط إلى مرحلة التحويل التالية

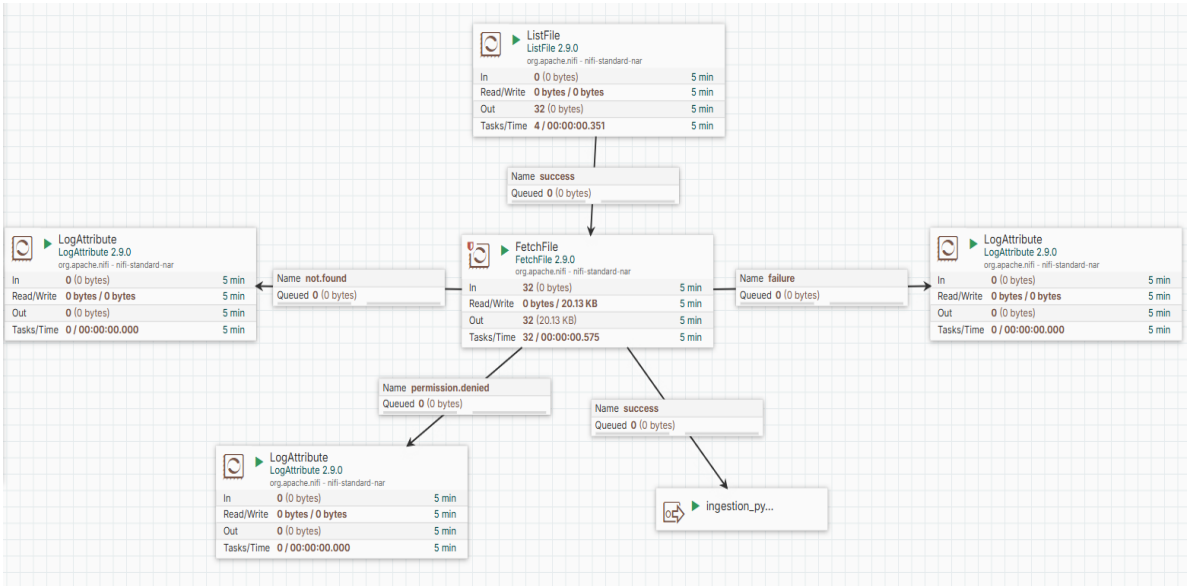

3. Database Ingestion

Connect NiFi to a relational database (MySQL, PostgreSQL, Oracle, etc.).
Use ExecuteSQL or QueryDatabaseTable and ensure incremental extraction instead of full loads.

استيعاب البيانات من قواعد البيانات

الهدف التقني: تأسيس اتصال مستدام مع قاعدة بيانات علائقية وتطبيق منهجية السحب التراكمي لضمان كفاءة معالجة البيانات

- إعداد بروتوكول الاتصال: تم تهيئة خدمة الاتصال وربطها بملف تعريف قاعدة بيانات بوستجرس لضمان استقرار قناة الاتصال بين نظام ناي فاي وقاعدة البيانات
- تطبيق السحب التراكمي: تم استخدام معالج الاستعلام التراكمي بدلاً من السحب الكامل وذلك لتقليل العبء على موارد النظام وضمان عدم تكرار جلب السجلات القديمة
- إدارة الحالة: تم تحديد حقل المعرف كعمود للقيمة القصوى حيث يقوم النظام آلياً بحفظ آخر قيمة تم سحبها وفي الدورات اللاحقة يبدأ بجلب السجلات التي تملك معرفاً أكبر فقط
- الجدولة الزمنية: تم ضبط وتيرة السحب لتكون كل ١٠ ثوان مما يضمن الحصول على البيانات بشكل لحظي مع تجنب إرهاق قاعدة البيانات أو الضغط غير الضروري على مواردها

التصميم التنظيمي: تم عزل هذه المرحلة داخل مجموعة معالجة مستقلة لسهولة الصيانة وفصل مهام الاستيعاب عن مراحل المعالجة الأخرى

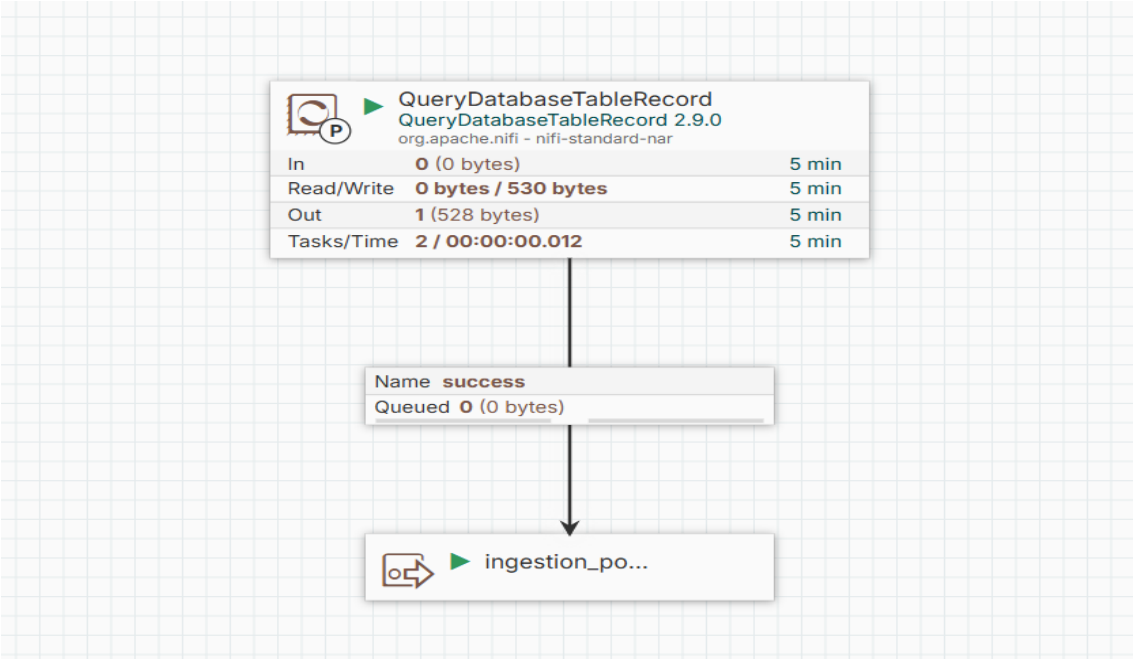

4. Data Transformations

Apply transformations such as data cleaning, format conversion, filtering, enrichment, and deduplication.

أ. التحقق من الهيكلية (ValidateRecord):

قمت بتصميم مخطط هيكلي مرن يسمح باستقبال البيانات سواء كانت نصوصاً أو أرقاماً عشرية وذلك لمنع توقف النظام عند استلام مبالغ مالية بصيغ مختلطة يتم توجيه أي سجل يخالف هذا المخطط آلياً إلى مسار البيانات غير الصالحة لضمان سلامة الأنابيب الرقمية من الانهيار

ب. التخلص من التكرار (DeduplicateRecord):

نفذت آلية ذكية للكشف عن المعرفات المتكررة داخل كل حزمة بيانات بشكل لحظي يتم عزل أي نسخة مكررة وتوجيهها إلى مسار المكررات

ج. المعالجة المتقدمة والاستعلام الذكي (QueryRecord):

- **الحقول المالية:** استخدمت تقنيات التحويل القسري للأنواع داخل الاستعلام وكذلك أي سجل لا يوجد فيه amount يتم ارساله الئ لوج يحتاج مراجعه
- **الحالات:** قمت بتوحيد الحالات المبهمة مثل علامات الاستفهام وتحويلها إلى غير معروف لضمان اتساق البيانات وتسهيل تحليلها لاحقاً
- **السجلات:** قمت بدمج أعمدة إضافية لكل سجل توثق نجاح المعالجة وطابع زمني لحظي يحدد وقت التنفيذ بدقة مما يسهل عمليات التتبع والمراقبة
- **الفرز المتعدد:** صممت مساراً مستقلاً للبيانات السليمة الجاهزة للتخزين ومساراً آخر مخصصاً للسجلات التي تفتقر للمبالغ المالية لتحويلها إلى المراجعة اليدوية
- **رفع كفاءة الأداء:** قمت بتجاهل توليد أي ملفات فارغة لا تحتوي على سجلات

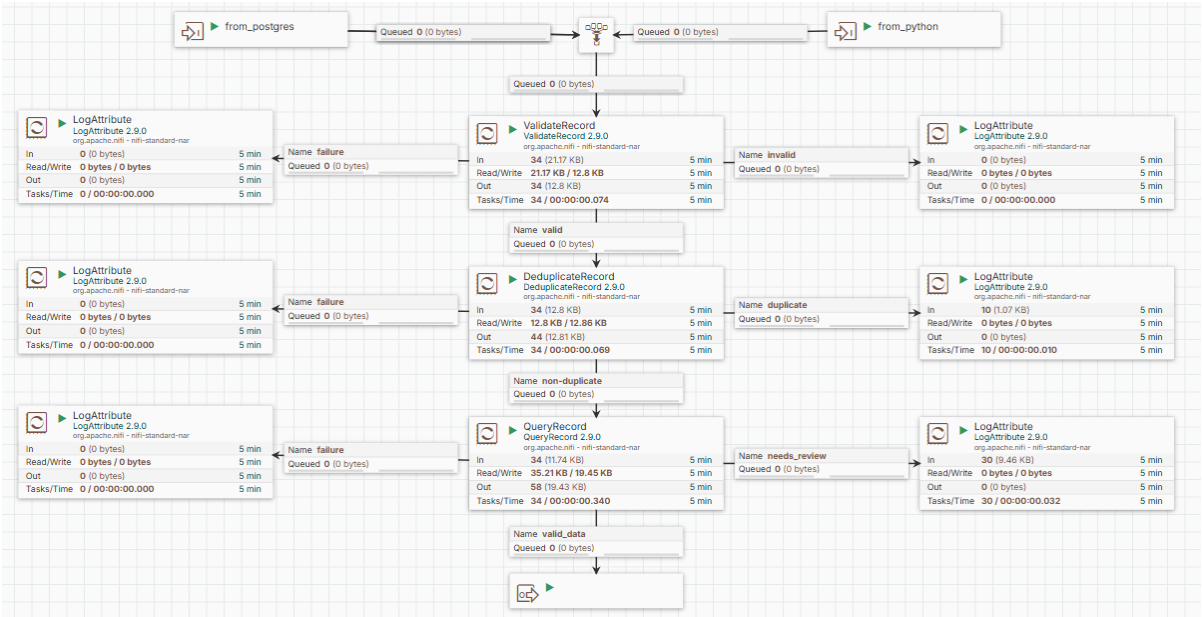

5. Load to HDFS

Store processed data into HDFS

استقبال البيانات:

قمت باستقبال البيانات الخارجة من مرحلة ال Transformation بعد اكتمال معالجتها وتحويلها إلى الشكل المطلوب

تجهيز الاتصال بنظام التخزين:

قمت بتهيئة الاتصال مع نظام الملفات الموزع والتأكد من أن مسار التخزين جاهز لاستقبال الملفات

تخزين البيانات:

بعد التأكد من جاهزية النظام قمت برفع البيانات وتخزينها داخل المسار المحدد في نظام الملفات الموزع بحيث أصبحت محفوظة ويمكن الرجوع لها في أي وقت

مخرجات المرحلة:

- حفظ البيانات المعالجة داخل نظام الملفات الموزع بشكل ناجح
- توفير نسخة محفوظة ومستقرة يمكن الاعتماد عليها مستقبلا

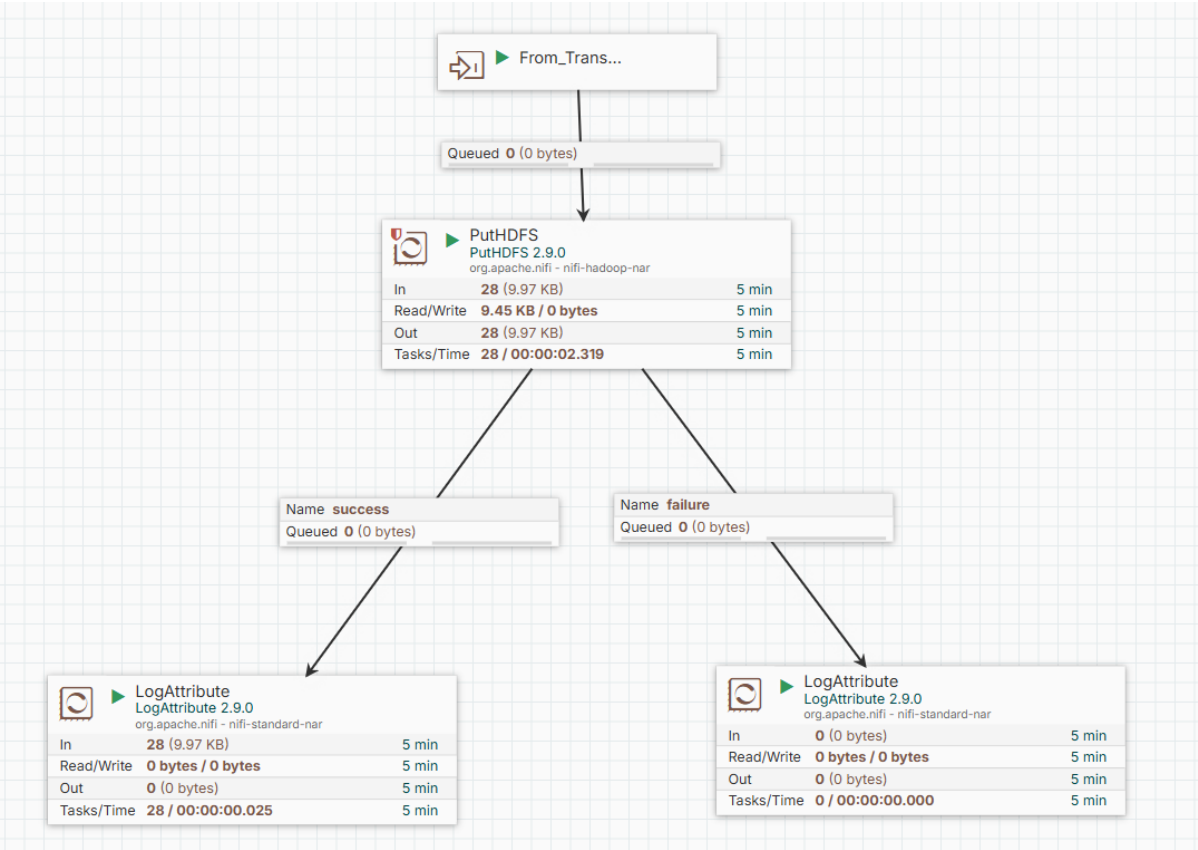

6. Apply NiFi Best Practices

Demonstrate usage of Back Pressure, Yield Duration, Retry & Penalization, Prioritizes (optional), and proper relationship handling.

:Back Pressure

- ضبطت حدود البيانات في الوصلات بين الطبقات لمنع التكدس وحماية الذاكرة من الاستنزاف عند زيادة تدفق البيانات

:Yield Duration

- حددت مدة عشر ثوان للمعالجات المرتبطة بأنظمة خارجية وهي إتش دي إف إس وبوستجرس للتوقف مؤقتاً عند الفشل لتقليل الضغط على النظام

:Retry & Penalization

- فعلت خاصية بناليزيشن لضمان عدم تكرار معالجة الملفات الفاشلة فوراً مما يعطي فرصة للنظام لاستعادة استقراره قبل المحاولة مجدداً طبقتها في معالج اللود الى ال hdfs

:Prioritizes

- استخدمت أولوية فرست ان فرست اوت في نقطة دمج البيانات التي في قسم معالجة البيانات

:relationship handling

- تجنبت خاصية الإغلاق التلقائي أوتو تيرمينيت ووجهت كافة حالات الفشل إلى معالج لوج أتريبيوت لضمان عدم ضياع أي بيانات وتسهيل تتبع الأخطاء

7. Additional Ingestion Techniques

Demonstrate at least one additional ingestion method such as Database or API.

جلب البيانات من قاعدة البيانات:

- استخدمت معالج كوييري داتابيس تيبل ريكورد للاتصال المباشر بقاعدة بيانات بوستجرس مما يتيح سحب البيانات المنظمة من الجداول وتحويلها آلياً لصيغة جيسون

جلب البيانات من سكربت بايثون:

- نفذت مساراً لسحب البيانات الناتجة عن سكربت بايثون خارجي حيث يقوم النظام بمراقبة المجلد المخصص وقراءة الملفات التي يولدها السكربت ومعالجتها فوراً وحذفها من الملف الاساسي مما يثبت قدرة النظام على التكامل مع الأدوات واللغات البرمجية المختلفة

Deliverables

1. NiFi Flow (template or screenshots)
2. Simulation Script
3. Architecture Diagram
4. Documentation explaining design decisions
5. Sample data before and after transformation

:NiFi Flow (template or screenshots)

- تم إرفاق صور العمل في ال pdf وسيتم إرفاق التمبلت

:Simulation Script

- سيتم إرفاق ملف السكربت الخاص بتوليد البيانات

:Architecture Diagram

- تم إنشاء جروب بروسسيسور أساسي يحتوي على مجموعه من الجروبز

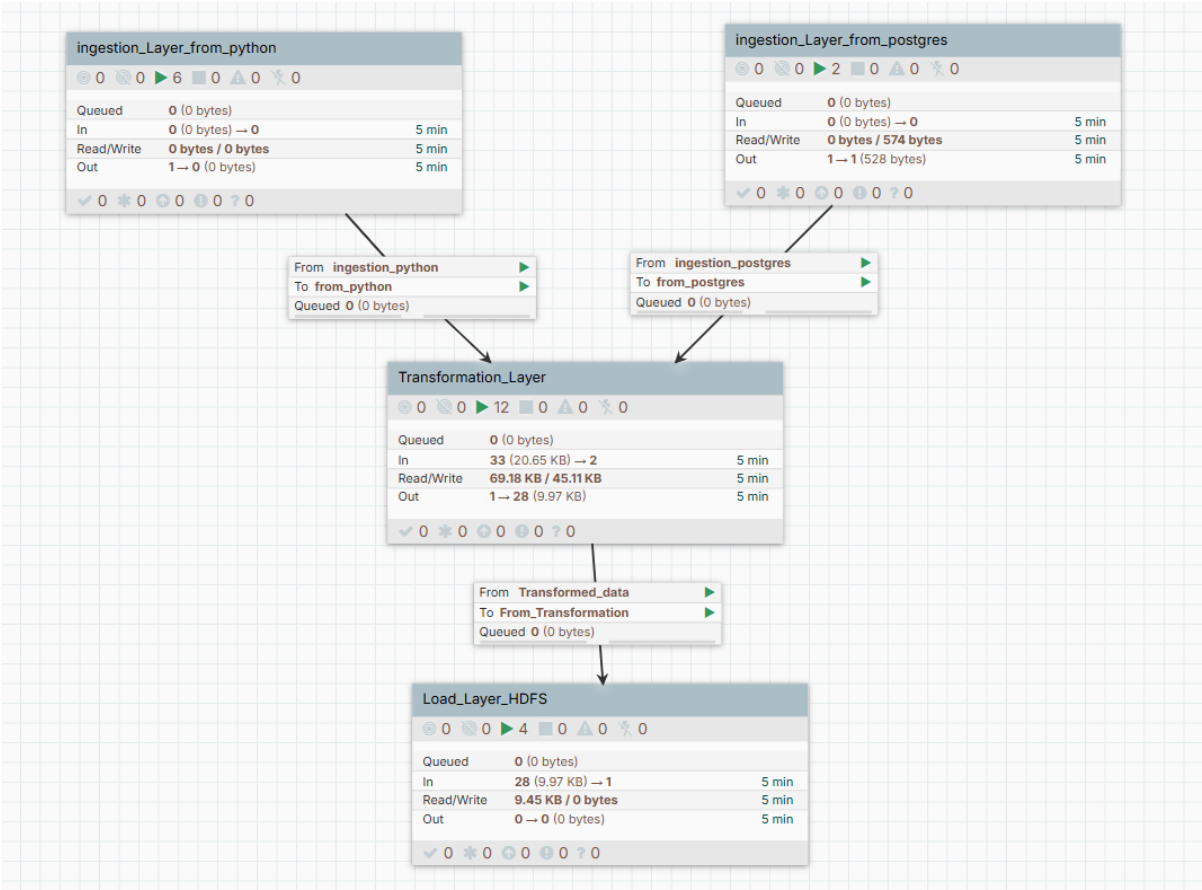

:Sample data before and after transformation

شكل للبيانات القديمة في Postgres ومن ثم البيانات نفسها في هدوب بعد معالجتها

Data Output Messages Notifications

Showing rows: 1 to 5 Page No: 1

	id [PK] integer	user_id integer	amount character varying (50)	timestamp timestamp without time zone	category character varying (50)	status character varying (50)
1	5001	2	200.75	2026-05-06 08:48:59.073021	Tech	Active
2	5002	4	missing	2026-05-06 08:48:59.073021	Food	???
3	5003	1	[null]	2026-05-06 08:48:59.073021	Fashion	Not_Active
4	5004	3	150.50	2026-05-06 08:48:59.073021	Tech	[null]
5	5005	3	150.50	2026-05-06 09:18:03.250269	Food	Active

والان شكل البيانات بعد المعالجة:


```
[
    {
        "id": 5001,
        "user_id": 2,
        "amount": "200.75",
        "status": "Active",
        "timestamp": "1778057339073",
        "category": "Tech",
        "quality_check": "Processed_Success",
        "nifi_process_time": 1778092327207
    },
    {
        "id": 5004,
        "user_id": 3,
        "amount": "150.50",
        "status": "Unknown",
        "timestamp": "1778057339073",
        "category": "Tech",
        "quality_check": "Processed_Success",
        "nifi_process_time": 1778092327207
    },
    {
        "id": 5005,
        "user_id": 3,
        "amount": "150.50",
        "status": "Active",
        "timestamp": "1778059083250",
        "category": "Food",
        "quality_check": "Processed_Success",
        "nifi_process_time": 1778092327207
    }
]
```